什么是智能体的"深度研究"：一个严格的定义，及据此给报告排名的方法与检验

What Is Deep Research by AI Agents? A Rigorous Definition, and a Report-Ranking Method and Pilot Study Built on It

作者：〔待填〕

工作稿，2026 年 10 月 29 日

摘要（Abstract）

深度研究智能体能针对一个问题自主检索、阅读，并写出带引用的长篇报告。这类产品和相应的评测基准都已大量出现，但"深度研究"本身一直没有严格的定义。我们检查了 2025 年 8 月至 2026 年 10 月间的 23 篇相关文献，发现：

- 只有一篇给出了可以检验的形式定义；
- "深"至少有六种用法，例如搜得多、推理跳数多、过程长、产出长；
- 四家厂商对自家产品的描述，说的都是过程的强度，没有一家说明"深"深在认识的什么地方。

没有定义，评测就不知道该测什么。构念效度检查清单的第一条，就是定义所测的现象。

本文的主要贡献，是给出一个相对严格的定义。 定义分三层：

- **调研**：为回答提问者的具体问题，以截至某一时间点已经存在的信息为材料，系统地查找、甄别、分析和整合，得出有理有据的结论。它的正面界定取自市场研究行业守则，反面界定取自《弗拉斯卡蒂手册》对研发的排除清单，即不以扩展人类知识的边界为目标。
- **好的调研**：合并情报分析、系统综述和叙述性综述三套成熟的质量标准，得到七个核心环节，写作列为二级。
- **深**：依据《实践论》对认识由浅入深的刻画，指调研对问题的认识从现象、片面和外部联系，推进到本质、全体和内部联系的程度。

深度研究，就是以推进到本质、全体和内部联系为目标的调研。这个定义：

- 有明确的外延和边界；
- 不循环；
- 能比较深浅；
- 能落到报告上观察：报告中的每条要点，都可以判为现象、全体、内部联系、本质四个层级之一。

定义的用处。

- **审视现有工具。** 以这个定义为尺子，我们审视了 18 个现有评测工具。七个核心环节乘以 18 个工具共 126 格，完整评到的只有 7 格；"深"的三项，9 个工具一项都不评。
- **推出评测方法。** 我们由定义推出一种评测方法：逐条核验结论、汇总要点池并按层级计分、以名次区间公布结果。

- **小规模检验。** 我们用 6 个产品对同一道题写的真实报告做了检验。故意改错、编造来源和注水都被识别；同一评委重评，环节评级的一致率为 83%。事先写定的 8 条验收标准中有 4 条没有通过，暴露的问题已在第 1.1 版中修订。
- **一个旁证。** 检验也印证了定义的一个推论：篇幅、来源数量，以及产品是否处于"深度研究模式"，都不等于定义意义上的深。

1 引言（Introduction）

1.1 背景

2024 年 12 月，谷歌在 Gemini 中推出 Deep Research [14]。2025 年 2 月，OpenAI [27] 和 Perplexity [28] 相继推出同类功能；2025 年 4 月，Anthropic 推出 Research [1]。这类产品接到一个问题后，会自主规划、多轮检索和阅读，最后写出带引用的报告。OpenAI 称之为"一种在互联网上为复杂任务进行多步研究的智能体能力"[27]。

评测随之大量出现。我们收集了 2025 年 8 月至 2026 年 10 月间的 23 篇相关文献，其中 16 篇各提出一个评测基准，2 篇提出评测框架，3 篇是测量研究，2 篇是综述。

1.2 问题

本文从一个实际需要出发：**比赛评审**。我们把同一道研究题交给 5 个智能体，各自独立完成并交付报告，再由评审排出名次。第一轮只对交上来的报告排名，不对智能体本身的能力下结论。

我们把"名次可信"分为三层：

- **测对了东西**：名次反映的是调研质量，而不是篇幅、文笔这类无关因素；
- **测得稳**：条件相同时重新评一次，名次基本不变；
- **经得起复核**：第三方能看清名次是怎么得出的，并能重算。

在比赛中，名次要公布，会被参赛者质疑，所以第三层的分量最重。

根本的难点在第一层：深度研究是什么，并没有说清楚。

- 23 篇文献中，只有 LiveDRBench [18] 给出了可以检验的形式定义，而它划定的门槛没有经过检验。
- 各篇所说的"深"，至少有六种用法：搜得多、推理跳数多、推理难度大、过程长、产出长、需要专业知识。
- 厂商对自家产品的描述，说的都是过程的强度（第 2.2 节）。

定义不清，评分维度的选择就只能凭直觉。于是各个评测工具各测一部分，而且常常把手段（搜得多）或无关因素（写得长）当成了深。Bean 等人对 445 个大语言模型评测基准的综述，把"定义所测现象"列为第一条建议 [4]。我们认为，对深度研究而言，这一条正是最薄弱的地方。

在定义之外，这个场景还有三个难点：

1. **样本小。** 一道题、五份报告，没有大量题目可以把误差平均掉。

2. **评委本身需要证明。** 多数评测工具用大语言模型当评委，评委判得对不对、稳不稳，是名次成立的前提。
3. **规则就是激励。** 比赛规则公布后，参赛者会照着规则优化：规则奖励什么，作品就会往哪里长。

1.3 贡献

1. **定义（主要贡献）。** 我们给出智能体"深度研究"的三层定义：调研、好的调研、深（第 3.1 节）。我们说它"相对严格"，是因为它满足六条要求：
    - 有内涵，也有外延；
    - 不循环；
    - 目的、手段、基础分层；
    - 能比较深浅；
    - 能落到报告上观察；
    - 每个成分都有成熟领域的出处，而不是从现有产品的共性中归纳出来的。
2. **以定义为尺子审视现有工具。** 我们按统一的框架审视了 18 个评测工具，归纳出 17 类共同问题，再按"从题目到名次"的推理步骤，归并为 8 个关键问题（第 2.7 节、第 3.2 节）。
3. **由定义推出评测方法。** 定义中的每个成分，都对应评测中的一个可观察的部件（第 3.1.7 节）。由此得到一种以核验为先、以要点池计深度、以名次区间公布结果的评测方法（第 3.2 至 3.7 节）。
4. **检验。** 我们在检验之前写定验收标准，用真实报告和人为构造的扰动版本做了小规模检验，并据检验结果修订方法（第 4 节）。

1.4 范围

本文只处理**基础级**：题目只用文字，一次给全，不交互。多模态材料的理解和研究过程中的交互，是两个独立的进阶形态，留待以后。

2 相关工作（Related Work）

2.1 深度研究评测工具

按判分对象，现有工具大致分为六类。

- **短答案的检索型。** BrowseComp-Plus [7] 用约 10 万篇人工核验的固定语料，使评测可以复现；LiveBrowseComp [11] 用新近的冷门事实出题，以堵住"凭记忆作答"的捷径；LiveDRBench [18] 给出了深度研究的形式定义，主张它的本质是搜索时的高扇出，而不是长报告。
- **长报告的评分项型。** 这是数量最多的一类：
- DeepResearch Bench II [21]：从专家文章中反推出约九千四百条二元评分项；
- DRACO [40]：题目来自 Perplexity 脱敏的真实请求；
- DailyReport [15]：150 道日常时效类题目，配级联的评分项；
- FinResearchBench II [22]：只保留"三个评委意见一致、并且能区分系统"的评分项；

- From Simple QA [35]：从简单问答出发，自动滚雪球式地扩展成深度研究题；
- LifeSearch [36]：生活与工作场景的真实需求；
- Expert Consulting [2]：结合确定性检查、专家评分和认知陷阱；
- DR³-Eval [39]：每道题配一个静态沙箱语料；
- MiroEval [24]：同时评报告、事实和过程；
- MMDeepResearch-Bench [16]：扩展到图文材料。
- **事实核查型**。 DeepFact [17] 提出"先审计后评分"，让核查器和标准答案共同演进。
- **两两比较型**。 DR-Arena [13] 由考官智能体现场出题、追问，再判胜负。
- **交互能力**。 IDRBench [12] 测智能体中途向用户澄清的能力。
- **评测框架与训练数据**。 DREAM [5] 让评委本身成为能联网的智能体，去查事实、时效和推理；DeepResearch-9K [38] 用大语言模型改写已有的多跳题，批量造出训练数据。

Anthropic 公开的工程说明 [42] 提到，它内部评测研究结果时看事实准确、引用准确、完整性、来源质量（一手来源优先）和工具使用效率。Ding 等人的综述 [9] 以"可核验性"为主线，梳理了科学研究智能体的评测，指出代码公开已经比可复现、可核验更常见。

2.2 现有文献与厂商对"深度研究"的界定

文献。 23 篇文献中，描述了深度研究的有 20 篇。它们都提到"由用户的问题驱动"；16 篇提到"多步、多跳或需要推理"，即一次检索解决不了。但只有 LiveDRBench [18] 给出了正式定义：

- 定义的内容是搜索强度加推理强度；
- 这个强度是相对的，取决于语料，以及一位"本来不知道答案的专家"；
- 它给出的门槛（专家借助搜索要 10 分钟以上，涉及 20 段以上材料），原文用的是"we posit"，没有数据支撑。

没有一篇定义过"研究"本身，也没有一篇规定调研所用材料的截止时间。各篇所说的"深"，至少有六种用法：

1. 搜得多（广度）；
2. 跳得多，即由上一步推出下一步要查什么；
3. 推理难；
4. 过程长；
5. 产出长；
6. 需要专长。

厂商。 深度研究最早是产品名，所以厂商的描述，是各篇文献共同的原型：

- 谷歌说，Gemini Deep Research 会先制定多步研究计划，然后反复搜索，"基于已经学到的东西开始新的搜索" [14]；
- OpenAI 称之为"一种在互联网上为复杂任务进行多步研究的智能体能力" [27]；
- Perplexity 说它"执行数十次搜索，阅读数百个来源" [28]；

- Anthropic 说 Research 会进行"彼此衔接的多次搜索" [1]；其工程说明主张"先广后窄"，并认为搜索的本质是"压缩"，即从大量材料中提炼洞见 [42]。

观察。 这些都是产品描述，不是定义。厂商所说的"深"，主要是过程的强度：搜得多，读得多，一环扣一环，省时间。触及"理解"的只有 Perplexity 的"在过程中加深理解"和 Anthropic 的"提炼洞见"两处。没有一家提到事情的性质、因果或历史。

由此形成了一种隐含的理解：**深 = 过程强度**。但过程强度是手段，不是结果。一份报告可以搜得很多、写得很长，认识却停在现象层面。第 3.1 节的定义，正是要把"深"从过程强度中区分出来。

2.3 测量研究

三篇测量研究直接关系到计分规则的设计：

- Rao 等人 [30] 用网页存档区分"编造的网址"和"后来失效的网址"，测得深度研究智能体的伪造率为 3% 至 13%。
- Wang 等人 [37] 发现，智能体在评测时会搜到评测基准自身的元数据甚至答案，使成绩最多虚高约 4 个百分点。
- Kalai 等人 [19] 论证，"答对得分、答错和弃答都不得分"的二元计分会鼓励模型瞎猜。

2.4 构念效度与评测基准的检查清单

构念与构念效度。 心理测量把人格、智力这类不能直接观察、只能通过测验间接推断的属性，称为"构念"。构念效度回答的问题是：一项测验是否真的测到了它想测的那个属性 [4, 8]。这个概念由 Cronbach 与 Meehl 系统阐述 [8]，最初用于为无法直接核实的心理属性设计测验。

Bean 等人 [4] 把它引入大语言模型评测。评测基准要测的"推理""安全"或"深度研究能力"，同样不能直接观察，只能用一组任务和一个计分指标来代理。构念效度高，高分才意味着具有这种能力；构念效度低，高分可能与这种能力无关，甚至会误导。

构念效度是一个总的概念，可以从几个侧面检查 [4]：

- **表面效度**：测验看上去是否像在测这个属性；
- **内容效度**：任务是否覆盖了这个属性的所有重要方面；
- **生态效度与预测效度**：测验与真实场景是否相关，能否预测以后的表现；
- **聚合效度、区分效度与效标效度**：测验结果是否与测同类属性的其他测验相关，并且只与它们相关。

已知组检验是常用的一种检验 [8]：如果事先知道两组对象在这个属性上有差别，测验结果就应当能把它们区分开。本文第 3.7 节和第 4 节的已知组检验即由此而来。

放到本文的场景中，要测的构念是"调研质量"，构念效度可能在两个方向上受损：

- **测进了无关的东西**，例如篇幅、格式和文笔。这对应 Bean 等人建议中的"只测该现象"。
- **漏掉了重要的方面**，例如"深"。这对应内容效度。

Bean 等人的系统综述。 Bean 等人 [4] 的语料来自两组会议：ICML、ICLR、NeurIPS 2018 至 2024 年的论文，以及 ACL、NAACL、EMNLP 2020 至 2024 年的论文，共 46,114 篇。他们按关键词筛出 2,189 篇，经

人工筛选后纳入 445 个大语言模型评测基准，由 29 位专家逐篇审阅。

他们把一个评测基准看作一条链：用一项任务把要测的现象操作化，用一个指标给任务计分，再根据分数对这个现象下结论。审阅发现：

- 78.2% 给出了所测现象的定义，但其中 47.8% 的定义存在争议；
- 只有 16.0% 做了统计检验；
- 只有 53.4% 论证过自己为什么是这个现象的有效测量。

八条建议与检查清单。 据此，他们提出八条建议，每条下面列出若干检查项，合计约 25 项（表 1）。他们指出，这份清单除了用来设计新的评测基准，也可以用来审视已有的评测基准。它的局限是只覆盖了主要学术会议上经过同行评议的论文，而深度研究领域的评测基准大多是预印本。

表 1　Bean 等人的八条建议与主要检查项（据原文第 5 节整理）

建议	主要检查项
1 定义所测现象	给出精确、可操作的定义；说明覆盖范围，承认没有覆盖的方面；现象有子成分时分别测量
2 只测该现象	控制无关任务对结果的影响；评估输出格式要求的影响；验证自动解析输出的准确性、一致性和偏差
3 构建有代表性的题目集	用合适的抽样方法使题目代表整个任务空间；核验题目的质量与相关性，尤其是大规模或自动生成的题目；加入测试已知敏感性的题目
4 承认复用数据集的局限	说明是否改编自已有数据集；分析其优缺点；与原数据集上的表现比较；说明改动如何提高构念效度
5 防范污染	实施污染检测；保留不公开的题目；调查题目材料是否已出现在常见的训练语料中
6 用统计方法比较模型	报告样本量并论证统计效力；为主要分数报告不确定性估计；使用人工评分者时说明其构成并减少偏差；使用能反映主观标签变异的指标
7 做错误分析	定性、定量地分析常见的失败；检查失败是否与非目标现象相关；讨论由此暴露的计分偏差
8 论证构念效度	说明评测与真实应用的关联；说明任务和指标的选择理由，并与操作性定义相联系；与测同类现象的已有评测比较；讨论构念效度方面的局限与取舍

论证式效度。 检查清单回答"查什么"，但没有回答"每一项检查在由分数得出结论的推理中处于哪一步"。Kane [20] 的论证式效度回答的是后一个问题。它把"由分数得出结论"看作一条推理链，逐环列出所依赖的假设，并为每个假设提供证据。链条有四个环节：

- **评分**：分数是否按规则正确打出；
- **推广**：在这批题目上的表现，能否代表同类题目上的表现；
- **外推**：评测中的表现，能否代表真实场景中的能力；
- **决策**：据分数做出的决定（例如排名、选型）是否合理。

任何一环缺少证据，结论就站不住。

两者的结合。 第 2.7 节的审视把两者结合起来：以 Kane 的四个环节为骨架，把 Bean 等人的检查项放到它所支撑的环节之下（表 2）。

表 2　论证环节与检查项的对应

论证环节	要回答的问题	对应的检查项（表 1中的建议编号）
评分	分数是否按规则正确打出	建议 2：格式影响、自动解析；建议 6：人工评分者、主观标签的变异；建议 7：计分偏差
推广	这批题目上的表现，能否代表同类题目	建议 3：抽样与题目质量；建议 6：样本量、统计效力、不确定性估计；建议 4：复用的局限
外推	评测中的表现，能否代表真实的深度研究能力	建议 1：定义、范围、子成分；建议 8：与真实应用的关联，任务与指标的选择理由；建议 7：失败是否与无关因素相关；建议 5：污染
决策	据分数得出的排序是否合理	建议 6：不确定性估计；建议 8：与同类评测的比较

Raji 等人 [29] 从另一个角度提出警告：以"通用能力"为名的评测基准，常常把有限的几项任务当作一种无边界能力的代表。

2.5 其他领域的质量标准

调研质量的标准，在若干成熟领域中早有积累：

- **情报分析。** 美国情报界的分析标准 ICD 203 [26] 规定了五条分析标准和九条技艺标准。其中包括"不应为了降低出错的风险而回避难下的判断"，以及"说明把握程度"。它还设有专门受理分析质量异议的申诉专员。
- **系统综述。** AMSTAR 2 [31] 明确反对把各项评分加成总分，理由是总分会掩盖致命缺陷；它的做法是事先指定关键项。
- **叙述性综述。** SANRA [3] 由三位资深编辑独立评分，组内相关系数为 0.77；"写作与可读性"一项因为分歧太大被删除。
- **研发统计与市场研究。** 《弗拉斯卡蒂手册》[25] 把市场调查、政策研究、咨询等活动排除在"研究与试验发展"之外；国际商会与欧洲民意和市场研究协会的守则 [41] 把研究定义为"系统地收集、分析和解释信息"，以支持决策。
- **认识的深化。** 关于"深"，我们采用《实践论》[23] 对认识过程的刻画：从现象、片面和外部联系，到本质、全体和内部联系；全体是"事情的历史和全部现状"。Marchionini [43] 把信息搜寻分为查找、学习和探究三类，"探究"大致对应本文所说的调研。

2.6 方法来源

- 信息检索评测中的汇总评估法 [32, 34]：把各系统的检索结果合在一起组成待判定的池，再由评估员独立判定相关与否。
- 心理测量中的成对比较法 [33] 与布拉德利－特里模型 [6]。
- 用于估计不确定性的自助重抽样法 [10]。

2.7 对现有工具的系统审视

做法。 我们按第 2.4 节表 2的框架审视每个工具，另加四个贯穿性问题：时效、污染、可复现、利益关系。每个工具写一份审视记录，每条判断标注证据等级：

- 复算：我们根据公开的数据或代码算过；

- 自述：只有论文自己的说法；
- 推断：根据原文推出，原文没有直接说。

审视对象是 18 个评测工具，另有 3 篇测量研究作为标尺。

结果。 表 3是主要数字。

表 3　18 个评测工具的审视结果

项目	结果
四个环节共 72 格的判定	有缺陷 39 格，证据不足 33 格，站得住 0 格
可复现站得住的工具	2 个（BrowseComp-Plus、DR³-Eval）
报告了评委与人工一致性的	11 个，多数样本小，或对照物不独立
给出置信区间或统计检验的	6 个
做了闭卷检查的	4 个
数据和代码都公开的	8 个
发布者自己的系统上了自己的榜	确定 5 个，可能 2 个
论文内部数字前后矛盾的	16 个

18 份审视记录共列出 273 条问题，归为 17 类，另有 8 条只在个别工具中出现但很重要。按影响名次的程度排序，前三类是：

1. **评委判分缺少独立、充分的人工对照。** 18 个工具都有这个问题。例如，DR-Arena 的标注员先看到了考官的判定，再回答是否同意；DailyReport 用同一批数据既挑选评委、又验证评委。
2. **名次差距落在噪声之内，没有不确定性估计。** 17 个工具。例如，DeepResearch Bench II 的第五、六名只差 0.02 分；对 MiroEval 纯文本组中两个相邻系统的逐题分做配对重抽样，分差的 95% 区间是 [−0.69, +1.98]，跨过了 0。
3. **计分只看一侧。** 10 个工具。只计命中而不罚说错，会奖励堆砌；只算精确率、判定宽松，会奖励回避。例如，LifeSearch 的输出词元数与得分的斯皮尔曼系数达到 0.797。

与"好的调研"的对照。 七个核心环节乘以 18 个工具共 126 格，完整评到的只有 7 格：

- "查找过程交代清楚"和"区分事实和判断"，没有一个工具当作评分项；
- "深"的三项（本质、全体、内部联系），9 个工具一项都不评；
- 11 个工具把各项加成总分；
- 有致命缺陷机制的 6 个工具，机制要么过窄，要么过宽。

我们没有拿自己的定义去指责论文"没有按我们的定义做"。这里只说明：对我们的场景而言，这几个环节没有现成的评法可以借用。

3 方法（Our Method）

3.1 深度研究的定义

3.1.1 什么样的定义算严格

我们给自己的定义提出六条要求：

1. **有内涵，也有外延。** 内涵是本质属性；外延说清楚哪些活动在内、哪些在外，以及边界在哪里。
2. **不循环。** 不用"深"来定义"深"，也不用"理解得深"来定义"深"。
3. **分层。** 目的、手段和基础分开说，不并列成一张清单。
4. **能比较。** 不只回答"是不是深度研究"，还要能回答"甲比乙深在哪里"。本研究的目标是排序，这一条必不可少。
5. **能观察。** "理解"是内在状态，看不见。定义必须说明，深在报告里表现为什么，并能区分"真深"和"假深"。
6. **有出处。** 每个成分都取自成熟领域的标准或经典论述，而不是从现有产品的共性中归纳。共性可能只来自共同的原型和共同的便利，并不等于正确。

3.1.2 调研

> **调研**是为了回答提问者的一个具体问题，以截至某一时间点已经存在的信息为材料，系统地查找、甄别、分析和整合，得出有理有据的结论的活动。结论可以是对现状和来龙去脉的描述、对原因的解释、对未来的预测，或对行动的建议；无论哪一种，都要讲得出道理、拿得出依据。调研不以扩展人类已有知识的边界为目标。基于智能体应用的实际情况，它也不通过问卷、访谈或其他手段收集新的一手资料。

没有一篇文献直接给"调研"下过公认的定义。我们从三个方向把它界定出来（表 4）：

- **正面**：市场研究行业守则把研究定义为"系统地收集、分析和解释信息"，以"产生洞见并支持决策"[41]。
- **反面**：《弗拉斯卡蒂手册》把研究与试验发展定义为"为增加知识存量而进行的创造性、系统性工作"，并明确把市场调查、可行性研究、政策分析、咨询等排除在外或列为边界 [25]。这些被排除的活动，正是调研这一家族的成员。
- **精神**：《反对本本主义》[45] 说，要调查"那个问题的现状和它的历史"，"一切结论产生于调查情况的末尾，而不是在它的先头"。

表 4　调研定义的成分与出处

成分	出处
为了回答提问者的一个具体问题	文献中描述深度研究的 20 篇都提到"由用户的问题驱动"；市场研究守则的"支持决策"

成分	出处
截至某一时间点已经存在的信息	《反对本本主义》的"现状和它的历史"；市场研究守则对二手资料的定义。现有文献的定义都没有时间点
系统地查找、甄别、分析和整合	市场研究守则的"systematic gathering, analysis and interpretation"
有理有据	《反对本本主义》的"没有调查，没有发言权"
四类结论：描述、解释、预测、建议	《反对本本主义》的"调查就是解决问题"；咨询实务的通行做法
不以扩展知识边界为目标	《弗拉斯卡蒂手册》第 2.5 段，表 2.1 第 a 条，以及排除清单
不收集新的一手资料	智能体应用的实际情况。这一条与市场研究守则和《反对本本主义》不同，二者都包括一手资料

"推出来的结论"算不算新知识。 一份调研报告可能得出前人没有写过的结论。按《弗拉斯卡蒂手册》的思路，分界线不在于结论是否第一次出现，而在于目的和材料：调研的目的是回答这一位提问者的问题，材料是已有的信息；研究的目的是推进人类知识的前沿。所以，得出新结论的调研仍然是调研。

外延。

- **在内的**：现状汇总、比较评估、来龙去脉与原因、预测、行动建议、核实某个说法。
- **不在内的**：以推进知识前沿为目标的科研；收集新的一手资料；不需要依据的创作；不查资料、只凭记忆作答。
- **是调研、但不一定"深"的**：一次检索就能回答的查找，例如"法国的首都是哪里"。

3.1.3 好的调研

调研是情报分析、医学证据综合等行业的本职工作，这些行业都有成文的质量标准。我们合并了三份：

- 情报分析标准 ICD 203 [26]，含 5 条分析标准和 9 条技艺标准；
- 系统综述评价工具 AMSTAR 2 [31]，含 16 项，其中 7 项为关键项；
- 叙述性综述量表 SANRA [3]，含 6 项。

合并后得到"好的调研"的两级要求。一级是七个核心环节，括号中注出主要出处：

1. 弄清问题背后的真实需要，审视问题的前提和其中概念的边界，回答的正是提问者要问的问题（ICD 203 技艺标准 5；SANRA 第 1、2 项）；
2. 所用材料截至规定的时间点，并且足够新（ICD 203 分析标准 c）；
3. 查找系统而全面，并交代查找过程（ICD 203 分析标准 d；AMSTAR 2 第 2、4、7 项；SANRA 第 3 项）；
4. 甄别来源的质量，处理相互矛盾的信息（ICD 203 技艺标准 1、4；AMSTAR 2 第 9、13、14 项）；
5. 分析时交代事情的历史和全部现状，讲清事情的性质和内在联系，推理清楚，区分事实和判断，考虑过其他解释，不为迎合提问者或某一方而扭曲结论（ICD 203 技艺标准 3、4、6，分析标准 a；SANRA 第 5 项；以及第 3.1.4 节）；
6. 每个结论都能追到依据，引用准确（ICD 203 技艺标准 1、6；SANRA 第 4 项）；

7. 结论准确、具体、清楚，敢于下判断，同时如实说明有多大把握（ICD 203 技艺标准 2、8；SANRA 第 6 项）。

二级是写作语言，列为可选指标。理由有两条：SANRA 原有"写作与可读性"一项，因为评分者之间分歧太大被删除；ICD 203 对呈现的要求，也只是"适当使用图表"。

两点说明。

- **"敢于下判断"与"如实说明把握"必须同时成立。** ICD 203 要求"不应为了降低出错的风险而回避难下的判断"；Kalai 等人 [19] 则论证，不罚错误会鼓励瞎猜。两者的调和点，就是下判断，并说明有多大把握。
- **这七个环节与"深"的关系，见下一小节的最后一段。**

3.1.4 深

我们依据《实践论》[23] 对"认识如何由浅入深"的刻画。它有四段与本题直接相关：

- 浅的认识："开始只是看到过程中各个事物的现象方面，看到各个事物的片面，看到各个事物之间的外部联系。"
- 深的认识："抓着了事物的本质，事物的全体，事物的内部联系了。……不但是数量上的差别，而且有了性质上的差别。"
- 两个词的解释："事情的全体（事情的历史和全部现状）"，"事情的本质（事情的性质及此一事情和其它事情的内部联系）"。
- 由浅入深的工夫："将丰富的感觉材料加以去粗取精、去伪存真、由此及彼、由表及里的改造制作工夫"。

据此定义：

> **调研的深**，是调研对问题的认识推进到什么程度：从事情的现象、片面和外部联系，推进到事情的本质、全体和内部联系。全体，是事情的历史和全部现状；本质，是事情的性质，以及这件事和其他事情之间的内在联系。推进得越远，调研就越深。
>
> 推进靠的是对丰富的材料去粗取精、去伪存真、由此及彼、由表及里。材料的丰富是深的基础。

对照第 3.1.1 节的六条要求：

- **不循环。** 用"从现象到本质的推进"来定义深，而不是用"深"或"理解得深"。
- **分层。** 第一段说深是什么；第二段说靠什么推进、以什么为基础。
- **能比较。** "推进得越远，调研就越深"，所以可以回答"甲比乙深在哪里"。
- **能观察。** 深落到报告上，就是报告中每条要点所处的层级：
- 现象：事情本身的事实和表面特征；
- 全体：历史和全部现状，包括容易忽略的方面、例外和反例；
- 内部联系：这件事与其他事情之间的因果、制约、依赖关系；

- 本质：事情的性质，以及为什么是这样。

这与教育评价中可观察学习成果结构分类法 [44] 的思路相通。这一分类法给书面回答的理解深度分级：只罗列多个方面，属于"多而不连"；把多个方面联成一个解释，才是结构上的变化。我们只核实了它的二手介绍，没有读原著。"堆砌背景"的假深，正是多而不连。 - **有出处。** 各项都出自同一个经典文本，"历史"一项也来自原文对"全体"的解释，不是从某个例子中归纳的。

与第 2.2 节六种用法的关系。 定义把那六种用法各自安放到了应有的位置：

- 搜得多，是"材料的丰富"，属于深的基础，不是深本身；
- 跳得多、过程长，是"推进的工夫"，属于手段；
- 产出长，与深无关；
- 推理难、需要专长，是题目的性质，不是调研的深。

一句话：**深是调研的深，不是过程的强，也不是题目的难。**

一个例子。 "法国的首都是哪里"是一次检索就能回答的查找，题目本身很浅。但如果用历史的眼光去看，查一查巴黎是否一直是法国的首都，认识就从现象推进到了全体。同一道题，调研可以浅，也可以深。

深不以提问者当下的需要为限。 提问者没有要求的深层内容，只要正确又切题，就算深。超出需要的部分，提问者下一轮自然不会追问。

与"好的调研"的关系。 深是统摄"好的调研"中深广部分的原理：

- "去粗取精、去伪存真"体现在第 4 环，即甄别；
- "由此及彼"体现在第 3 环，即多步查找；
- "由表及里"体现在第 5 环，即分析与整合；
- "丰富的材料"体现在全面查找。

切题、时效、有据、结论准确清楚，属于可靠与可用，不属于深。所以，一份报告可能深而不可靠，例如推出了深刻的联系，依据却是编造的；也可能可靠而不深。评测必须把两者分开看。

3.1.5 深度研究与智能体的深度研究

> **深度研究**（深度调研），是以推进到本质、全体和内部联系为目标的调研。
>
> **智能体的深度研究**，是由智能体自主完成的深度研究。它交付一份报告，报告包括五个部分：主要结论在前；论证与解释；出处（链接、取用日期、原始出处）；把握程度；查找与来源说明。

交付形式的五个部分，都由前面的定义推出：

- "有理有据"要求论证与出处；
- "如实说明把握"要求写明把握程度；
- "交代查找过程"要求写明查找与来源。

范围。本文只处理基础级：题目只用文字，一次给全，不交互。在此之上有两个彼此独立的进阶形态：

- **多模态**：题目附带图片或文件；
- **交互**：允许开始前澄清需求、过程中调整方向、交付后追问。

两个进阶形态都以基础级为底。一份多模态报告，首先仍然要是好的调研。

3.1.6 与现有界定的比较

表 5　三种界定的比较

方面	LiveDRBench [18]	厂商描述 [1, 14, 27, 28]	本文
"研究"是什么	没有定义	没有定义	调研：正面、反面和精神三个方向的界定
"深"指什么	搜索强度与推理强度	过程强度：搜得多、读得多、多步	认识推进的程度：从现象、片面、外部联系到本质、全体、内部联系
时间点	没有	没有	截至某一时间点
边界	以门槛划定，门槛没有检验	没有	不扩展知识边界；不收集一手资料；不凭记忆作答
能否比较深浅	相对于语料和专家	不能	推进得越远，越深
能否在报告上观察	按断言是否齐全、正确计分，不涉及认识的层次	不能	要点的四个层级

这里有一处有意的偏离：本文的定义比厂商的自我描述要求更高。厂商的描述，都落在定义第二段"推进靠的工夫"那一层；第一段"从现象推进到本质"，厂商的描述里没有。

3.1.7 从定义到评测

定义的每个成分，都对应评测中一个可以观察的部件（表 6）。第 3.3 至 3.7 节的方法，就是把这张表付诸实施。

表 6　定义的成分与评测部件

定义中的成分	在报告中观察什么	评测部件
回答提问者的具体问题；弄清真实需要	是否写明自己的理解和假设，是否审视问题的前提	环节评级第 1 环
截至某一时间点，并且足够新	材料的日期，信息是否过时	断言核验中的时效评级
系统地查找	是否交代查找的范围、方法和局限	环节评级第 3 环
甄别	是否说明来源的可靠程度，是否处理矛盾	环节评级第 4 环；来源标签
分析与整合；深	要点所处的层级；是否区分事实和判断；是否考虑其他解释	要点池的四个层级；环节评级第 5 环
有理有据	结论能否追到来源，来源是否支持结论	来源标签；硬伤"编造来源""没有可追溯的出处"

定义中的成分	在报告中观察什么	评测部件
结论准确，敢下判断，说明把握	对错；是否回避判断；是否说明把握	对错标签；环节评级第 7 环；硬伤"直接回答有误"
材料的丰富是深的基础，不能替代深	不同的、正确的、切题的要点，而不是篇幅和来源数量	深度净分
写作（二级）	可读性	单独报告，不进入名次

3.2 从关键问题到设计

我们把一份报告变成一个公布的名次的过程，拆成八步，每一步对应一个关键问题（表 7）。

表 7　关键问题与对应的设计

步骤	关键问题	主要设计
1 出题	题目能否拉开差距，又不替智能体做理解	题目卡与深度地图；"挖深会改变结论"检验
2 作答	各份报告是否在同等条件下产生	统一运行规程；交付包；24 小时内存档被引网页
3 定依据	尺子能否认出好调研和"深"	断言核验；要点池；环节评级
4 判定	评委是否准确、稳定、无偏	多家族评委组；重复评；交换位置；人工审计关键判定
5 计分	奖励什么、惩罚什么、怎样合成	硬伤分档；深度净分；环节评级不加总；写作单列
6 定先后	差距能否与噪声分开	三种权重加重抽样；名次区间
7 证明	名次是否反映调研质量	扰动测试；独立专家两两判断
8 公布	第三方能否复核	复核包；一致性核对；申诉渠道

3.3 出题与收集

题目卡写明问题、提问者、用途和截止时间，不写要查的实体和方法，也不提示深度。

出题人另写一份**深度地图**，不给智能体看，内容是：只看现象时答案是什么，推进到本质、全体、内部联系之后，结论或建议在哪里会改变。我们用"挖深会改变结论"作为题目留有挖深空间的判据。例如"中国最大的淡水湖是哪一个"：只看现象，答案是鄱阳湖；考虑季节变化、历史上的变迁，以及"最大"按面积还是按蓄水量来算，对一位少儿科普编辑来说，书里这句话应当怎样写就变了。

深度地图只作为要点池的来源之一，不作为唯一的判分参照。另外，题目要经过第二人检查有没有泄露答案，再用不参赛、也不同源的模型做闭卷对照。

收集。 各产品同一天运行，截止时间定为运行当天，一律使用深度研究模式。智能体提出澄清问题时，一律回复："题目已包含全部信息，请按你的理解直接进行，并在报告中写明你的理解和假设。"交付包包括报告、完整的来源网址和运行模式截图；导出时丢失的出处，从分享链接中补救，并记录补救过程。被引网页在 24 小时内存档。评审前统一格式，去掉产品名。

3.4 判分依据

判分依据分为三部分。

断言核验。 每份报告抽出主要结论，打两类标签。

- **来源标签**，六种：
- 支持；
- 部分支持；
- 不支持；
- 失效但有存档；
- 找不到（疑似编造），须经第二次核查才能确认；
- 没有出处。
- **对错标签**，三种：正确、有误、无法判断，以截止时间为准独立核对。

核验还给出时效评级。

要点池。 把出题人深度地图上的要点，和各份报告的要点合在一起，意思相同的合成一条。对每条池中要点，判定四件事：

- 对不对；
- 切不切题；
- 层级：现象、全体、内部联系、本质；
- 重要性：核心或一般。

然后记下每份报告写到了哪些要点、写对了还是写错了。

要点池与"从参赛报告反推评分标准"不同。报告只提供"有哪些要点可以判定"，每条要点的对错和层级，按来源和定义判定，与有几份报告提到它无关。这与信息检索中的汇总评估法同理 [32, 34]。这样，出题人没有想到、但正确又切题的内容也能得分，而这正是"深"的主要表现。

环节评级。 对切题与真实需要、查找过程的交代、甄别来源与处理矛盾、分析、结论与把握五个环节，各按写好的三档描述评 0、1、2 分。每个评级都必须引用报告原文为证。

3.5 计分与合成

硬伤（第 1.1 版），共四种：

1. 确认的编造来源；
2. 报告对题目的直接回答（至多 3 条总体判断）被可靠证据否定；
3. 答非所问；
4. 经补救仍没有可追溯的出处。

有硬伤的报告，排在所有没有硬伤的报告之后。格式、篇幅、文笔，永远不算硬伤。

深度净分。 记要点池为 P。对报告 r 和权重方案 w：

$$N_w(r) = \Sigma_{p \in P^+(r)} \lambda_w(\text{层级 } p) \times \iota(p) \;-\; \Sigma_{p \in P^-(r)} \varepsilon(p) \;-\; 0.5 \times U(r)$$

- $P^+(r)$：报告写对了的、正确且切题的要点；
- $P^-(r)$：报告写错了的要点，即把正确的要点写反，或者写了有误的内容；

- 层级 p：要点 p 的层级；
- ι(p)：重要性权重，核心为 2，一般为 1；
- ε(p)：错误的扣分，核心为 2，一般为 1；
- U(r)：所引来源不支持的主要结论条数。

层级权重 λ_w 预先声明三种方案：

方案	现象	全体	内部联系	本质
甲	0	1	1	1
乙	0	1	2	2
丙	0.5	1	1.5	2

为什么材料多本身不加分。 "广是深的基础，但广不能替代深"。在这套规则里，这一点体现为：材料不足，就写不出正确的深层要点；而同一个要点写好几遍，或者写了现象层的背景，都换不来分。

环节评级不加总。 只有在深度净分分不开的时候，才比较各环节。一份报告在五个环节和时效上都不差于另一份，并且至少一项更好，才排在前面。

写作单列，不进入名次。

3.6 分辨力与名次区间

对要点池做 1,000 次有放回的重抽样。

分开的条件。 报告 x 排在 y 前面，当且仅当下列三种情况之一成立：

1. x 没有硬伤，y 有硬伤；
2. 二者硬伤状态相同，并且在三种权重下 `N_w(x) > N_w(y)` 都成立，每种权重下在至少 90% 的重抽样中也都成立；
3. 二者的深度净分在两个方向上都分不开，但 x 的环节评级在上述意义上优于 y。

两两比较的否决。 我们另请评委对每一对报告按两种先后做整体比较，作为第二条路线。如果两次都判 y 胜，第 2、3 种情况下的"x 在前"就不成立。第 1.1 版规定，两两比较不能否决第 1 种情况，即由核验确认的硬伤。

名次区间。 报告 x 的名次区间为

```
[ 1 + 确定排在 x 前面的报告数 ,  n − 确定排在 x 后面的报告数 ]
```

分不开的报告并列。如果比赛的奖项需要唯一的名次，并列的报告由独立专家做两两判断来决定，不用写作好坏来决定。

3.7 效度检验、验收标准与复核

效度检验。 一套测对了东西的评法，应当在报告故意变差时降分，在加入无关内容时不升分。我们构造了三种扰动版本：

- 改错版：改错几处主要结论中的事实；
- 注水版：加入约三成正确、但与问题无关的背景；
- 编造版：把一处来源换成编造的网址。

正式比赛时，还要对每一对分开的相邻报告，请一位看不到分数的独立专家做两两判断；专家不同意的那一对，改为并列。

验收标准。 验收标准在检验之前写定，检验之后不改阈值；没有通过，就修改方法，不修改标准。小规模检验可以检验的有 8 条（表 9）。正式比赛时另加 3 条：

- 人工审计中，评委与人工的一致率至少 85%；
- 独立专家同意公布的先后，至少占四分之三；
- 依次去掉每一家厂商的评委，公布的先后都不改变。

复核。 复核包包括：

- 题目卡和深度地图；
- 原始报告和统一格式后的报告；
- 被引网页的存档，附时间和校验值；
- 全部评委提示词、原始输出和模型版本；
- 要点池及每条判定的依据；
- 计分代码。

公布的数字只能由代码生成，并由另一人独立重算。申诉期内，所有参赛者都可以就具体判定提出异议，由不参与评分的人裁决。

4 实验（Experiments）

4.1 材料

我们使用 2026 年 3 月 3 日收集的一批真实报告：同一道题交给 6 个产品，题目大意是"各家大语言模型的深度研究功能哪家做得最好，请做综合分析"。原题文本没有保存，我们根据各报告的标题和开头还原了题目，截止时间定为 2026 年 3 月 3 日。六份报告随机编为 A 至 F，并去掉了标题中的产品名（表 8）。

表 8　六份报告

编号	产品	长度（字符）	出处情况	备注
A	ChatGPT	41,389	有引注标记，但导出后没有网址	英文原文
B	Claude	1,237	无	看起来是普通对话，不是 Research 模式
C	Kimi	31,709	无	
D	Gemini	84,529	文末有来源列表，没有逐条对应到结论	附有研究过程的叙述
E	Perplexity	6,251	正文有链接	
F	DeepSeek	1,849	无链接，但提到了具体的评测名称	看起来是普通联网问答

扰动版本。 以 E 为底，做出原版、改错版、注水版和编造版四个版本，随机编为 P1 至 P4，各由一个独立的评委完整评审。

- 改错版改动了三处主要结论中的事实：两个评测分数（21.1% 改为 41.1%，93.9% 改为 73.9%），以及完成一次任务的用时（"几分钟内"改为"两到三个小时"）。
- 注水版加入 1,910 字的背景，内容是搜索引擎和语言模型的发展史，约占原文的三成。
- 编造版把一处来源换成一个无法解析的域名下的网址。

4.2 评委与运行

所有评委都是 Claude 家族的模型（Claude Opus 与 Claude Sonnet，2026 年 10 月的版本），作为彼此隔离的子智能体运行。

任务	评委	规模
环节评级与要点抽取	Opus 两次（第二次倒序阅读），Sonnet 一次	每次 6 份报告
断言核验	Opus	58 条主要结论
断言核验的稳定性	Sonnet 独立重核	15 条
两两比较	Opus 两次，第二次交换每对的先后	15 对 × 2
扰动版的完整评审	Opus，每个版本一个评委	4 份，共 40 条主要结论
要点池的合并与判定	Opus	457 条原始条目与深度地图的 8 条，合并为 122 条
标注"对题目的直接回答"	Sonnet	第 1.1 版用

122 条池中要点中：

- 按层级：现象 80 条，全体 13 条，内部联系 23 条，本质 6 条；
- 按对错：正确 81 条，无法判断 30 条，有误 11 条；
- 判为不切题的 8 条，其中包括注水版加入的那条背景。

4.3 验收结果

表 9　验收结果（第一版规则）

编号	标准	结果	实际情况
1	复算一致	通过	两次重算完全相同
2	改错：查出至少 2 处，净分在三种权重下都降低	通过	查出 3 处，净分在三种权重下都降低
3	注水：净分在三种权重下都不升高	未通过	升高 0.5
4	编造来源：被标为"找不到（疑似编造）"	通过	被标出，第二次核查确认

编号	标准	结果	实际情况
5	已知组：对话模式的回答，不排在同档的深度研究报告前面	未通过	一处违反
6	稳定：同一评委的环节评级一致率至少 70%，两个评委的核验标签一致率至少 80%	通过	83%；来源标签和对错标签都是 93%
7	位置偏向：交换先后后判定改变的对数，不超过 25%	未通过	4/15，即 27%
8	分项计分与两两比较不矛盾	未通过	一处矛盾

附带的数字：不同模型的评委之间，环节评级的完全一致率为 67% 至 70%，低于同一模型重评的 83%。

4.4 名次区间

表 10　名次区间（只用于说明方法给出什么样的结果，不是对这些产品的评价）

报告	第一版	第 1.1 版	硬伤（第 1.1 版）	深度净分（甲 / 乙 / 丙）	写作
D（Gemini）	1 – 4	1 – 2	无	8 / 18 / 25.5	1
F（DeepSeek）	1 – 2	1 – 2	无	8 / 12 / 18	2
A（ChatGPT）	3 – 6	3 – 4	无	−2 / 1 / 12	1
E（Perplexity）	5 – 6	3 – 4	无	−4 / −2 / 6.5	2
C（Kimi）	2 – 5	5 – 6	直接回答有误；没有可追溯的出处	6 / 17 / 23	1
B（Claude）	2 – 5	5 – 6	没有可追溯的出处	4 / 8 / 16	2

第 1.1 版一列，包括第 4.6 节的修订 1，以及修订 3 中可以直接重算的部分。在第 1.1 版下，六份报告分成三档，每档两份。这与第 1.2 节的预期一致：只有一道题时，名次分不到一个一个那么细。

4.5 分析

1. **扰动测试说明，核验和要点池是有效的。**
   - 改错版的三处错误，全部被独立的核验员判为"有误"。
   - 编造的网址被识别了出来。
   - 注水版加入的背景被判为不切题，没有得到任何分数。注水版之所以比原版高 0.5 分，是因为两位核验员各自挑选要核验的结论：原版的核验员挑中了一条"来源不支持"的结论并扣了分，注水版的核验员没有挑到。标准 3 没有通过的原因是抽样带来的噪声，不是注水得了分。
2. **第一版的硬伤规则过宽，等于奖励少说。** 第一版规定，任何一条核心结论有误，就算硬伤。结果六份报告中有五份被判了硬伤，唯一幸免的是一份不到两千字的对话回答。结论写得越多，越可能有一条错，所以这条规则惩罚的是覆盖面。这正是第 2.7 节所说的"计分只看一侧"，只不过方向相反。标准 8 的那处矛盾也由此而来：分项计分把 F 排在 D 前面，两两比较却两次都判 D 胜。

3. **"深度研究模式"不是调研质量的已知组。** F 看起来是普通的联网问答，但它的核心结论全部正确，时效评级最高。它还是唯一指出"有的评测是厂商自己发布的，并且自家排第一"的报告，而这一条正是深度地图中的核心要点。反过来，A 和 E 依据的是过时的信息，例如把一年前的产品状态当作现状。两两比较这条路线没有用到任何核验结果，也两次都判 F 胜过 A、胜过 E。两条路线互相独立，得出了同样的判断。所以标准 5 没有通过，是已知组的预设本身错了，不是评法的问题。产品用了什么模式，不能代替对报告本身的检查。

4. **只读文字的整体判断，分辨不了"看起来深"和"真的对"。** 两两比较两次都判 C 胜过 A 和 E。但核验显示，C 对题目的直接回答是一组与事实不符的综合评分，全篇也没有可以追溯的出处。两两比较的评委不查事实，所以会被篇幅长、结构完整、但内容过时的报告说服。

5. **评委内部的稳定性够用，跨模型的稳定性较弱。** 同一模型重评的一致率是 83%，不同模型之间是 67% 至 70%。正式比赛采用多家族评委组、取中位数，是有必要的。

6. **深度地图的覆盖情况。** 深度地图的 8 条要点中，有 2 条没有任何报告写到，例如"'深度研究'不是一个标准化的能力，各家定义不同"和这类产品的发展过程；还有 4 条只有一两份报告写到。这说明这道题确实留有挖深的空间，而各份报告挖到的程度不同。

7. **定义的一个推论在检验中得到印证：篇幅和过程强度不等于深。** 按要点池统计，各份报告写对的深层要点数（全体、内部联系、本质三层合计）如下：

   - C：31,709 字符，15 条；
   - D：84,529 字符，14 条；
   - A：41,389 字符，9 条；
   - F：1,849 字符，5 条；
   - B：1,237 字符，4 条；
   - E：6,251 字符，3 条。

   由此可见：

   - A 的长度是 C 的约 1.3 倍，深层要点却少了 6 条；
   - E 是深度研究模式的产物，带有链接，深层要点却最少，它的内容大多停在现象层；
   - 从整个要点池看，122 条中有 80 条是现象层。

   这与第 2.2 节的观察一致：以过程强度为特征的产品，产出的内容大多是现象层的罗列。同时也要看到，深与可靠是两回事：C 的深层要点最多，但它对题目的直接回答有误，全篇也没有可以追溯的出处，所以在第 1.1 版中落在最后一档。这正是第 3.1.4 节最后一段所说的情况：深而不可靠。

4.6 修订（第 1.1 版）

修订	针对	内容
1	分析第 2 条	硬伤"主要结论与证据相反"收窄为"对题目的直接回答与证据相反"。支撑性事实的错误，照常在深度净分中扣分

修订	针对	内容
2	分析第 1 条	带来源的结论全部核验，另加至多 10 条不带来源的主要结论；结论清单由一人按固定规则抽出，所有核验员共用。扰动测试中，原版和扰动版使用同一份清单
3	分析第 4 条	两两比较不能否决由核验确认的硬伤。两两比较至少由两个评委、各按两种先后比较，四次中至少三次一致才能否决
4	分析第 3 条	已知组只用人为构造的扰动版本。标准 5 改为"一份报告的扰动版本，不排在它自己的原版前面"

修订 1 和修订 3 的前半，可以直接在本次数据上重算：

- 四个扰动版本中，只有编造版被判了硬伤；
- 标准 8 改为通过；
- 名次区间见表 10。

因为修订是在看过这批数据之后才做的，这只能算敏感性检查，不能算通过检验。标准 3、5、7 要在重新运行评委之后才能检验。

4.7 效度威胁

1. **评委同源。** 所有评委都来自 Claude 家族，而被评报告中有一份来自 Claude。所以跨家族的稳定性和同源偏向，这次都没有检验。
2. **材料不规范。** 题目是还原的，不符合题目卡的写法；深度地图是在读过部分报告之后写的。
3. **要点池没有人工复核。** 要点池由一个评委合并和判定。
4. **两两比较不完全独立。** 两两比较的评委在一个上下文中读完了全部六份报告，各对之间的判断不完全独立。
5. **人工环节没有做。** 人工审计和独立专家判断都没有做。
6. **材料已经过时。** 报告产生于 2026 年 3 月，各产品此后都已更新。

5 结论（Conclusions）

5.1 主要结论

本文的主要价值，是给智能体的"深度研究"下了一个相对严格的定义。 定义分三层：

- **调研**：以截至某一时间点已有的信息为材料，为回答具体问题而系统地查找、甄别、分析和整合，不以扩展知识边界为目标；
- **好的调研**：来自三套成熟质量标准的七个核心环节，写作列为二级；
- **深**：认识从现象、片面和外部联系，推进到本质、全体和内部联系的程度。

深度研究，就是以推进到本质、全体和内部联系为目标的调研。

与现有的界定相比，这个定义有三点不同：

1. 把"深"从过程强度（搜得多、写得长）中区分出来，指向认识推进的程度；

2. 给出了时间点和边界；
3. 能比较深浅，并能落到报告中每条要点的层级上观察。

定义的用处在于，它让评测知道该测什么。 以它为尺子，我们发现现有的 18 个评测工具，对"好的调研"的七个核心环节完整评到的只有 7 格（共 126 格），对"深"的三项多数不评。

由定义推出的评测方法有四个要点：

1. 以逐条核验为先；
2. 用汇总的要点池承认出题人没有想到的深层内容，并只给正确、切题、不重复的要点计分；
3. 用硬伤分档、不加总的环节评级、三种预先声明的权重和重抽样，只公布站得住的先后；
4. 以名次区间公布结果。

小规模检验表明，这套方法能识别故意改错、编造来源和注水。检验也印证了定义的推论：篇幅、来源数量和产品模式都不等于深，深与可靠也必须分开评。

5.2 对比赛评审的建议

- 公布名次区间，而不是硬排的第几名；
- 篇幅、格式、文笔不进入名次；
- 说错要扣分，回避判断也要失分；
- 评委来自多家厂商，人工审计集中在会改变名次的判定上；
- 全部材料赛后公开，并设申诉渠道。

5.3 下一步

1. **正式检验。** 按本文的收集规程收集一批新报告：两道题，同一天在 3 到 6 个产品上用深度研究模式运行。在新报告上检验第 1.1 版，包括跨家族评委、人工审计和独立专家判断。
2. **扩展到"智能体谁强"。** 这需要多道题，并且每个智能体要重复运行，那时推广环节就要提供证据。
3. **进阶形态。** 多模态材料的理解和研究过程中的交互，是两个独立的进阶形态，都要以本文的基础级为底。

5.4 数据与代码

六份匿名报告、扰动版本、题目卡、深度地图、全部评委输出、要点池、计分程序和结果，都保存在 `research-plan/stage5-pilot/` 目录下。运行 `python3 -I score.py mapping.json 1.1` 即可重算表 9 和表 10。评审细则见 `research-plan/stage4-rubric.md`。

参考文献（References）

[1] Anthropic. Claude takes research to new places [EB/OL]. 2025-04-15.

[2] Asthana T, Saksena A, Sahu D. Evaluating Deep Research Agents on Expert Consulting Work: A Benchmark with Verifiers, Rubrics, and Cognitive Traps [J]. arXiv:2605.17554, 2026.

[3] Baethge C, Goldbeck-Wood S, Mertens S. SANRA—a scale for the quality assessment of narrative review articles [J]. Research Integrity and Peer Review, 2019, 4: 5.

[4] Bean A M, et al. Measuring what Matters: Construct Validity in Large Language Model Benchmarks [C]. NeurIPS 2025 Datasets and Benchmarks Track. arXiv:2511.04703.

[5] Ben Avraham E, Li C, Dorfman R, et al. DREAM: Deep Research Evaluation with Agentic Metrics [J]. arXiv:2602.18940, 2026.

[6] Bradley R A, Terry M E. Rank analysis of incomplete block designs: I. The method of paired comparisons [J]. Biometrika, 1952, 39(3/4): 324 – 345.

[7] Chen Z, Ma X, Zhuang S, et al. BrowseComp-Plus: A More Fair and Transparent Evaluation Benchmark of Deep-Research Agent [J]. arXiv:2508.06600, 2025.

[8] Cronbach L J, Meehl P E. Construct validity in psychological tests [J]. Psychological Bulletin, 1955, 52(4): 281 – 302.

[9] Ding T, Nannapaneni A, Liu B, Zhang L. Autonomous Research Agents: A Survey of AI Scientists and the Verification Gap [J]. arXiv:2608.05179, 2026.

[10] Efron B. Bootstrap methods: another look at the jackknife [J]. The Annals of Statistics, 1979, 7(1): 1 – 26.

[11] Fan H, Wang X, Chu Z, et al. LiveBrowseComp: Are Search Agents Searching, or Just Verifying What They Already Know? [J]. arXiv:2605.28721, 2026.

[12] Feng Y, Huang Q, Xie X, et al. IDRBench: Benchmarking the Interactive Capabilities of Deep Research Agents [J]. arXiv:2601.06676, 2026.

[13] Gao Y, Zhao R, Deng Y, Zhang W. DR-Arena: an Automated Evaluation Framework for Deep Research Agents [J]. arXiv:2601.10504, 2026.

[14] Google. Gemini: Try Deep Research and Gemini 2.0 Flash Experimental [EB/OL]. 2024-12-11.

[15] Han J, Liu W, Zhu M, et al. DailyReport: An Open-ended Benchmark for Evaluating Search Agents on Daily Search Tasks [J]. arXiv:2606.12871, 2026.

[16] Huang P, Zhong Z, Wan Z, et al. MMDeepResearch-Bench: A Benchmark for Multimodal Deep Research Agents [J]. arXiv:2601.12346, 2026.

[17] Huang Y, Ribeiro L F R, Hardalov M, et al. DeepFact: Co-Evolving Benchmarks and Agents for Deep Research Factuality [J]. arXiv:2603.05912, 2026.

[18] Java A, Khandelwal A, Midigeshi S, et al. Characterizing Deep Research: A Benchmark and Formal Definition [J]. arXiv:2508.04183, 2025.

[19] Kalai A T, Nachum O, Vempala S S, Zhang E. Why Language Models Hallucinate [J]. arXiv:2509.04664, 2025.

[20] Kane M T. Validating the interpretations and uses of test scores [J]. Journal of Educational Measurement, 2013, 50(1): 1 – 73.

[21] Li R, Du M, Xu B, et al. DeepResearch Bench II: Diagnosing Deep Research Agents via Rubrics from Expert Reports [J]. arXiv:2601.08536, 2026.

[22] Luan B, Sun R, Wang S, et al. FinResearchBench II: A Deep Research Benchmark with Consensus-Derived Gold Rubrics for Distinguishing Financial Report Quality [J]. arXiv:2607.12252, 2026.

[23] 毛泽东. 实践论 [M]. 1937.

[24] MiroMind Team. MiroEval: Benchmarking Multimodal Deep Research Agents in Process and Outcome [J]. arXiv:2603.28407, 2026.

[25] OECD. Frascati Manual 2015: Guidelines for Collecting and Reporting Data on Research and Experimental Development [M]. Paris: OECD Publishing, 2015.

[26] Office of the Director of National Intelligence. Intelligence Community Directive 203: Analytic Standards [S]. 2015.

[27] OpenAI. Deep research system card [R]. 2025-02-25.

[28] Perplexity. Introducing Perplexity Deep Research [EB/OL]. 2025-02-14.

[29] Raji I D, Bender E M, Paullada A, Denton E, Hanna A. AI and the Everything in the Whole Wide World Benchmark [C]. NeurIPS 2021 Datasets and Benchmarks Track.

[30] Rao D, Wong E, Callison-Burch C. Detecting and Correcting Reference Hallucinations in Commercial LLMs and Deep Research Agents [J]. arXiv:2604.03173, 2026.

[31] Shea B J, Reeves B C, Wells G, et al. AMSTAR 2: a critical appraisal tool for systematic reviews that include randomised or non-randomised studies of healthcare interventions, or both [J]. BMJ, 2017, 358: j4008.

[32] Sparck Jones K, van Rijsbergen C J. Report on the need for and provision of an "ideal" information retrieval test collection [R]. British Library Research and Development Report 5266. Cambridge: Computer Laboratory, University of Cambridge, 1975.

[33] Thurstone L L. A law of comparative judgment [J]. Psychological Review, 1927, 34(4): 273 – 286.

[34] Voorhees E M, Harman D K, eds. TREC: Experiment and Evaluation in Information Retrieval [M]. Cambridge, MA: MIT Press, 2005.

[35] Wang C, Chen H, Gao H, et al. From Simple QA to Deep Research: A Verifiable Benchmark Constructed through Iterative Task Evolution [J]. arXiv:2608.02163, 2026.

[36] Wang Y, Jin S, Ning Y, et al. LifeSearch: Benchmarking Deep Research Agents for Real-World Life and Productivity [J]. arXiv:2610.18092, 2026.

[37] Wang Y, Zhang X, Yao K, et al. Search-Time Contamination in Deep Research Agents: Measuring Performance Inflation in Public Benchmark Evaluation [J]. arXiv:2606.05241, 2026.

[38] Wu T, Wang Y, Ma X, et al. DeepResearch-9K: A Challenging Benchmark Dataset of Deep-Research Agent [J]. arXiv:2603.01152, 2026.

[39] Xie Q, Xiong Q, Zhu H, et al. DR³-Eval: Towards Realistic and Reproducible Deep Research Evaluation [J]. arXiv:2604.14683, 2026.

[40] Zhong J, Zhang H, Southern C, et al. DRACO: a Cross-Domain Benchmark for Deep Research Accuracy, Completeness, and Objectivity [J]. arXiv:2602.11685, 2026.

[41] ICC/ESOMAR. ICC/ESOMAR International Code on Market, Opinion and Social Research and Data Analytics [S]. 本文所据为 2025 年修订版.

[42] Anthropic. How we built our multi-agent research system [EB/OL]. 2025-06-13.

[43] Marchionini G. Exploratory search: from finding to understanding [J]. Communications of the ACM, 2006, 49(4): 41 – 46.

[44] Biggs J B, Collis K F. Evaluating the Quality of Learning: The SOLO Taxonomy (Structure of the Observed Learning Outcome) [M]. New York: Academic Press, 1982.

[45] 毛泽东. 反对本本主义 [M]. 1930.